Гайд по собеседованиям: Junior/Middle+ Data Scientist

Станьте частью Big Tech: Яндекс, VK, Сбер, Т-Банк, Ozon Tech

Рынок найма в Big Tech — закрытый клуб. Попасть туда случайно невозможно: у гигантов индустрии свои стандарты, ожидания и логика отбора. Часто отказывают не «слабым», а «неформатным» — тем, кто не знает, **как именно здесь принято решать задачи**.

Этот гайд станет вашим **личным консультантом** на пути к офферу. Он даст чёткую инструкцию: как перестать мечтать о работе мечты — и начать в ней работать.

Кому подойдёт?

- **Студентам** — дорожная карта для попадания на стажировку в топовые компании.
- **Джуниорам и мидлам** — план апгрейда карьеры: от текущего уровня до оффера в Big Tech.
- **Международным специалистам** — универсальные паттерны для собеседований в Москве, Лондоне, Берлине и других городах.

Что внутри? Полный охват направлений ML/AI

Мы собрали ключевые темы, которые спрашивают на интервью в Big Tech:

- **Классический ML:** алгоритмы, метрики, работа с дисбалансом, диагностика моделей.
- **Deep Learning:** нейронные сети, CNN, RNN, Transformers, оптимизация обучения.
- **Generative AI:** GAN, VAE, диффузионные модели, text-to-image.
- **Reinforcement Learning:** MDP, Q-learning, policy gradient, actor-critic.
- **NLP:** токенизация, embeddings, BERT, GPT, prompt engineering.
- **Computer Vision:** object detection, segmentation, Vision Transformer.
- **RecSys:** collaborative filtering, hybrid systems, deep learning в рекомендациях.
- **MLOps:** деплой моделей, мониторинг, CI/CD, Docker, Kubernetes.

Почему этот гайд полезен?

- **Структурированность.** Вопросы разбиты на логические блоки: от теории к практике, от простого к сложному.
- **Актуальность.** Акцент на востребованных направлениях: GenAI, MLOps, RecSys.
- **Практическая ценность.** Вопросы имитируют реальные интервью в Яндексе, VK, Сбере и др.
- **Целевая подготовка.** Каждый раздел закрывает конкретные пробелы в знаниях.
- **Масштабируемость.** Гайд можно обновлять и дробить на модули — он останется актуальным с развитием технологий.

Что вы получите?

С этим гайдом вы:

- Системно подготовитесь к интервью — от базовых вопросов до сложных кейсов.
- Выявите пробелы в знаниях и сосредоточьтесь на слабых местах.
- Постройте чёткий план обучения без хаотичных прыжков между темами.
- Проведёте самопроверку и оцените готовность к собеседованию.

- Поймёте логику интервьюеров: какие подходы ценят, каких ошибок стоит избегать.
- Сэкономите время — получите единую структурированную базу вместо разрозненных материалов.

Систематизированный список вопросов по классическому ML

1. Основы и диагностика моделей

Что такое overfitting и underfitting? Как их диагностировать?
Объясните trade-off между смещением (bias) и дисперсией (variance).
Назовите жизненные этапы разработки модели в проекте машинного обучения.
Что такое мультиколлинеарность? Как её обнаружить и устранить?
Какие предположения лежат в основе линейной регрессии? Как проверить их выполнение?
Что произойдёт, если в линейной регрессии целевая переменная (target) или фичи будут иметь ненормальное распределение?

2. Метрики качества

Какие метрики качества классификации вы знаете? (Accuracy, Precision, Recall, F1, ROC-AUC).
В чём разница между precision, recall, F1? Когда какой приоритетнее?
Объясните концепцию confusion matrix. Как из неё получить Precision, Recall и F1-score?
Что показывает ROC-кривая? Как интерпретировать значение AUC?
В чём разница между ROC-AUC и PR-AUC? Когда лучше использовать PR-кривую?
Что такое log-loss и для каких задач он применяется?
Сравните MSE, MAE и RMSE. Как каждая из этих метрик реагирует на выбросы?
Что такое MAE и MAPE? В каких задачах лучше использовать MAPE?
Как оценить качество регрессионной модели, если данные содержат много выбросов?
Какие метрики качества вы будете использовать для задачи классификации с несбалансированными классами?
Почему accuracy — плохой выбор метрики при дисбалансе классов?

3. Линейные модели

В чём отличие логистической регрессии от линейной?
Как интерпретировать веса в линейной регрессии?
Как работает логистическая регрессия? Почему для классификации используется именно сигмоида?
Объясните геометрическую интерпретацию L1- и L2-регуляризации в контексте линейной регрессии.
В чём разница между Ridge и Lasso регрессией с точки зрения отбора признаков?
Как интерпретировать коэффициенты в логистической регрессии? Что такое odds ratio? Что такое dummy variable trap и как его избежать при кодировании категориальных признаков?

4. Деревья решений и ансамбли

Как работает решающее дерево (decision tree)? Что такое энтропия и прирост информации (information gain)?
Опишите критерий Джини и энтропию для построения решающих деревьев.
Как обрезать дерево решений?
Объясните устройство случайного леса. Зачем нужен bootstrap?
Как выбрать оптимальное количество деревьев в случайном лесу?
Что такое out-of-bag (OOB) error в случайном лесу и как его использовать?
Как интерпретировать важность признаков в ансамблях деревьев?
Что такое feature importance в деревьях? Какие есть способы посчитать?
Чем отличаются bagging и boosting?
Объясните разницу между bagging и boosting. Приведите примеры алгоритмов каждого типа.
Как работает градиентный бустинг? Чем XGBoost отличается от классического GBM?
В чём преимущество LightGBM перед XGBoost? Какие есть недостатки?
Как работает алгоритм AdaBoost? Почему он чувствителен к выбросам?
Что такое early stopping в градиентном бустинге и как его реализовать?
Что произойдёт с градиентным бустингом, если убрать из ансамбля один слабый ученик (estimator)?
Что такое stacking? Как построить двухуровневый стэкинг?
Объясните концепцию ансамблирования моделей. Приведите примеры успешных ансамблей.

5. Кластеризация

Объясните принцип работы алгоритма k-means. Как выбрать оптимальное число кластеров k?
В чём отличие DBSCAN от k-means? Какие гиперпараметры есть у DBSCAN?
Опишите иерархическую кластеризацию. Чем агломеративный подход отличается от дивизивного?
Какие метрики можно использовать для оценки качества кластеризации, если у нас нет истинных меток?
Что такое silhouette score и как его интерпретировать?
Объясните разницу между KNN и кластеризацией k-средних.

6. Уменьшение размерности

Объясните суть метода главных компонент (PCA).
Объясните математический принцип работы PCA. Что такое главные компоненты?
Как интерпретировать explained variance ratio в PCA?
Как выбирать количество компонент в PCA?
В чём ключевое отличие t-SNE от PCA? Для каких задач лучше подходит каждый метод?
Чем t-SNE отличается от PCA и UMAP?
Что такое LDA (Linear Discriminant Analysis) и чем он отличается от PCA?

Какими способами можно уменьшить размерность набора данных?
Когда стоит применять уменьшение размерности перед обучением модели?
Какие могут быть минусы?

7. Предобработка данных

Как обрабатывать пропущенные значения в данных перед обучением модели?
Как бы вы поступили с отсутствующими данными в наборе данных?
Как обрабатывать пропуски (missing values) и выбросы (outliers)?
Что такое one-hot encoding и когда его стоит применять?
Что такое feature scaling? Чем отличаются StandardScaler и MinMaxScaler?
Когда стоит применять логарифмическое преобразование к признакам?
Как обрабатывать категориальные признаки с высокой кардинальностью?
Что такое target encoding и какие проблемы с ним могут возникнуть?
Как создавать полиномиальные признаки? В чём риск их использования?
Что такое interaction features и как они могут улучшить модель?
Опишите pipeline предобработки данных от сырых данных до финальных признаков.

8. Работа с дисбалансом классов

Что такое дисбаланс классов и какие методы борьбы с ним существуют?
Какие методы борьбы с дисбалансом классов вы знаете? Опишите SMOTE.
В чём разница между undersampling и oversampling? Какие у них плюсы и минусы?
Что такое stratified sampling и зачем он нужен при кросс-валидации в задачах с дисбалансом?

9. SVM и KNN

Объясните принцип работы SVM. Что такое kernel trick?

Почему в Random Forest не нужна нормализация признаков, а в SVM нужна?

Опишите алгоритм k-ближайших соседей (k-NN). Какие у него преимущества и недостатки?

10. Кросс-валидация и сравнение моделей

Опишите процесс кросс-валидации. Какие типы кросс-валидации вы знаете?
В чём разница между KFold и StratifiedKFold?
Как сравнивать две модели статистически значимо (McNemar, Wilcoxon, bootstrap и т. д.)?

11. Регуляризация

В чём разница между L1- и L2-регуляризацией? Приведите примеры алгоритмов, где они применяются.

12. A/B-тесты и статистика

Что такое p-value? Как его интерпретировать в контексте A/B-теста?
В чём разница между ошибкой первого рода (Type I) и ошибкой второго рода (Type II)?
Что такое statistical power? Как увеличить мощность теста?
Как определить необходимый размер выборки для A/B-теста?
Что такое multiple testing problem и как с ним бороться?

Список вопросов по Deep Learning

1. Основы нейронных сетей

Объясните архитектуру полносвязной нейронной сети (Fully Connected Network).
Что такое функция активации? Перечислите основные функции активации (ReLU, Sigmoid, Tanh, Softmax).
Сравните ReLU, Sigmoid и Tanh: преимущества и недостатки каждой.
Что такое проблема исчезающего градиента (vanishing gradient)? Какие функции активации помогают её решить?
Что такое проблема взрывающегося градиента (exploding gradient)? Как с ней бороться?
Объясните принцип работы обратного распространения ошибки (backpropagation).
Что такое градиентный спуск? Опишите его вариации: SGD, Momentum, Nesterov.

2. Оптимизация и обучение

В чём разница между SGD, Adam и RMSprop?
Что такое learning rate? Как выбрать оптимальный learning rate?
Что такое learning rate scheduling? Какие стратегии вы знаете (step decay, exponential decay, cosine annealing)?
Что такое batch size? Как его выбрать?
В чём отличие между batch, mini-batch и stochastic gradient descent?
Что такое epoch? Чем он отличается от iteration?
Что такое early stopping и как его реализовать?
Как диагностировать проблемы с обучением нейронной сети (застревание в локальных минимумах, плохая сходимость)?

3. Регуляризация и предотвращение переобучения

Что такое переобучение (overfitting) в контексте DL? Как его диагностировать?
Объясните принцип работы dropout. Как он помогает предотвратить переобучение?
Что такое batch normalization? Как он работает и зачем нужен?
В чём разница между batch normalization, layer normalization и instance normalization?
Что такое weight decay? Как он связан с L2-регуляризацией?
Какие методы регуляризации используются в DL помимо dropout и weight decay?
Что такое data augmentation? Приведите примеры техник для изображений и текста.

4. Свёрточные нейронные сети (CNN)

Объясните принцип работы свёрточных слоёв (convolutional layers).
Что такое kernel (фильтр) в CNN? Как размер ядра влияет на результат?
Что такое padding? Какие типы padding вы знаете?
Что такое stride в свёртке? Как он влияет на размер выхода?
Что такое pooling? Какие типы pooling вы знаете (max pooling, average pooling)?
Опишите архитектуру LeNet. В чём её ограничения?
Опишите архитектуру AlexNet. Какие инновации она внесла?
Опишите архитектуру VGG. В чём её особенности?
В чём преимущество ResNet перед обычными CNN? Что такое residual connections?
Что такое bottleneck layer в ResNet?
Опишите архитектуру Inception. В чём идея параллельных свёрток разных размеров?
Что такое depthwise separable convolutions (MobileNet)? В чём их преимущество?

5. Рекуррентные нейронные сети (RNN)

Объясните принцип работы стандартной RNN. В чём её основные ограничения?
Что такое проблема исчезающего градиента в RNN? Как LSTM и GRU решают эту проблему?
Опишите архитектуру LSTM. Что такое gates (вход, забывание, выход)?
Опишите архитектуру GRU. Чем она отличается от LSTM?
Что такое bidirectional RNN? Когда её стоит использовать?
Что такое sequence-to-sequence модели? Где они применяются?
Что такое teacher forcing? Какие проблемы с ним связаны?

6. Attention и Transformers

Что такое attention mechanism? Объясните концепцию на примере seq2seq моделей.
Что такое self-attention? Как он работает?
Опишите архитектуру Transformer. Какие основные компоненты входят в encoder и decoder?
Что такое multi-head attention? Зачем он нужен?
Что такое positional encoding? Почему он необходим в Transformer?
В чём преимущество Transformer перед RNN для обработки последовательностей?
Что такое masked self-attention в decoder части Transformer?

7. Transfer Learning и Fine-tuning

Что такое transfer learning в контексте DL? Приведите примеры.
Как применять transfer learning для задач CV (на примере ImageNet предобученных моделей)?
Как применять transfer learning для NLP (на примере BERT, GPT)?
Опишите процесс fine-tuning предобученной модели.
Что такое feature extraction vs fine-tuning? В чём разница подходов?

Что такое progressive unfreezing при fine-tuning?

8. Генеративные модели

Что такое автоэнкодеры (Autoencoders)? Как они работают?
В чём отличие вариационных автоэнкодеров (VAE) от обычных автоэнкодеров?
Как работают генеративно-состязательные сети (GAN)? Опишите архитектуру генератора и дискриминатора.
Какие проблемы возникают при обучении GAN? (mode collapse, нестабильность обучения)
Что такое Wasserstein GAN (WGAN)? Чем он лучше классического GAN?
Опишите архитектуру StyleGAN. В чём её инновации?
Что такое conditional GAN? Приведите примеры применения.

9. Практические аспекты и отладка

Как инициализировать веса в нейронных сетях? Какие методы инициализации вы знаете?
Что такое gradient clipping? Когда его стоит применять?
Что такое label smoothing? Зачем его используют?
Как обрабатывать несбалансированные данные в DL?
Что такое mixed precision training? В чём его преимущества?
Как мониторить процесс обучения нейронной сети? Какие метрики и графики стоит отслеживать?
Что такое model checkpointing? Как его реализовать?

10. Архитектура и масштабирование

Что такое U-Net? Где она применяется?
Что такое EfficientNet? В чём идея compound scaling?
Что такое Vision Transformer (ViT)? Как он адаптирует Transformer для изображений?
Что такое MLP-Mixer? Чем он отличается от ViT?
Что такое Swin Transformer? В чём его отличие от классического ViT?

11. Интерпретация и объяснение моделей

Что такое saliency maps? Как их получить?
Что такое Grad-CAM? Как он помогает интерпретировать CNN?
Как визуализировать активации нейронов в глубоких сетях?
Что такое adversarial examples? Как они создаются и как защищаться от них?

12. Распределённое обучение

Что такое data parallelism? Как он реализуется?

Что такое model parallelism? Когда его стоит использовать?
Что такое pipeline parallelism? Приведите пример фреймворка для распределённого обучения (PyTorch DDP, Horovod).

13. Компромисс смещения и дисперсии (Bias-Variance Tradeoff) в контексте DL

- Как смещение (bias) и дисперсия (variance) проявляются в нейронных сетях?
- Какая модель имеет высокий bias, а какая — высокую variance?
- Как регуляризация (dropout, weight decay) влияет на bias и variance?
- Почему очень глубокие сети могут иметь высокую variance?

14. Градиентный спуск (продвинутые нюансы)

- Что такое сходимость градиентного спуска? Как понять, что модель сошлась?
- Что такое локальный минимум и седловая точка? Какая из этих проблем опаснее для DL?
- Как влияет ландшафт функции потерь (loss landscape) на обучение?
- Что такое плоские (flat) и острые (sharp) минимумы? Какие лучше обобщаются?

15. Функции активации (редкие и современные)

- Что такое Leaky ReLU и Parametric ReLU (PReLU)? Зачем нужен "negative slope"?
- Что такое ELU (Exponential Linear Unit)? Чем он лучше ReLU?
- Что такое Swish/SiLU? Почему эта функция стала популярна в современных моделях?
- Что такое GELU (Gaussian Error Linear Unit)? Где применяется (BERT, GPT)?

16. Dropout (детали реализации)

- Почему dropout масштабирует активации на инференсе (inverse dropout)?
- Чем dropout отличается от DropConnect?
- Можно ли использовать dropout после batch normalization? Какие есть рекомендации?

17. Batch Normalization (детали реализации)

- Какие параметры обучаются в batch normalization (gamma, beta)?
- Как работает batch normalization на инференсе (использование скользящего среднего)?
- Почему размер батча важен для batch norm? Что делать при маленьком батче (batch size = 1 или 2)?

Вопросы по Generative AI (GEN AI)

1. Основы генеративных моделей

Что такое генеративные модели? Чем они отличаются от дискриминативных?
Перечислите основные типы генеративных моделей и кратко опишите их принцип работы.
Что такое likelihood-based модели? Приведите примеры.
Что такое energy-based models? Как они работают?

2. Автоэнкодеры

Объясните принцип работы автоэнкодеров (Autoencoders).
В чём отличие вариационных автоэнкодеров (VAE) от обычных автоэнкодеров?
Что такое reparameterization trick в VAE? Зачем он нужен?
Как интерпретировать latent space в VAE?
Что такое β-VAE? Как параметр β влияет на обучение?

3. GAN и их вариации

Как работают генеративно-состязательные сети (GAN)? Опишите архитектуру генератора и дискриминатора.
Какие проблемы возникают при обучении GAN? (mode collapse, нестабильность обучения)
Что такое Wasserstein GAN (WGAN)? Чем он лучше классического GAN?
Что такое gradient penalty в WGAN-GP?
Опишите архитектуру StyleGAN. В чём её инновации?
Что такое conditional GAN? Приведите примеры применения.
Что такое CycleGAN? Как он работает без парных данных?
Что такое Pix2Pix? Где он применяется?

4. Diffusion Models

Объясните принцип работы диффузионных моделей.

Что такое forward и reverse diffusion process?
Как обучается диффузионная модель?
В чём преимущество диффузионных моделей перед GAN?
Опишите архитектуру U-Net в контексте диффузионных моделей.
Что такое classifier-guided diffusion?
Как ускорить процесс генерации в диффузионных моделях? (DDIM, PLMS)
Сравните диффузионные модели и VAE.

5. Оценка генеративных моделей

Как оценить качество генеративной модели?
Что такое FID (Fréchet Inception Distance)? Как он рассчитывается?
Что такое IS (Inception Score)? В чём его ограничения?
Какие ещё метрики используются для оценки генеративных моделей?

6. Практические аспекты

Что такое latent diffusion models (например, Stable Diffusion)?
Как fine-tune диффузионную модель под конкретный стиль?
Что такое text-to-image generation? Опишите pipeline.
Как работает guidance scaling в диффузионных моделях?
Приведите примеры использования GEN AI в индустрии.

Вопросы по NLP (Natural Language Processing)

1. Основы обработки текста

Что такое токенизация? Какие методы токенизации вы знаете (word-level, subword, BPE, SentencePiece)?
Объясните концепцию word embeddings. Сравните Word2Vec и GloVe.
Что такое contextual embeddings? Приведите примеры (BERT, ELMo).
Что такое POS-tagging? Какие подходы используются?
Что такое dependency parsing? Как его решить?

2. Архитектура Transformer

Опишите архитектуру Transformer. Какие основные компоненты входят в encoder и decoder?
Что такое self-attention? Как он работает?
Что такое multi-head attention? Зачем он нужен?
Что такое positional encoding? Почему он необходим в Transformer?
В чём разница между encoder-only и decoder-only моделями?

3. Pretrained Language Models

Опишите архитектуру BERT. Как он обучается (MLM, NSP)?
В чём отличие BERT от GPT?
Что такое RoBERTa? Чем он отличается от BERT?
Что такое ALBERT? Какие техники сжатия используются?
Опишите архитектуру T5. В чём идея text-to-text подхода?

4. Задачи NLP

Что такое Named Entity Recognition (NER)? Как его решить?
Объясните задачу машинного перевода. Какие подходы существуют?
Как оценить качество машинного перевода? (BLEU, METEOR, ROUGE)
Что такое sentiment analysis? Какие подходы используются для его решения?
Опишите задачу question answering. Какие архитектуры применяются?
Что такое summarization? В чём разница между extractive и abstractive summarization?

5. Fine-tuning и Prompt Engineering

Как дообучить (fine-tune) LLM под конкретную задачу?
Что такое few-shot learning в контексте LLM?
Что такое prompt engineering? Приведите примеры эффективных промптов.
Что такое chain-of-thought prompting?
Что такое instruction tuning?
Как работает retrieval-augmented generation (RAG)?

6. Оценка и этика

Какие проблемы существуют у современных LLM? (галлюцинации, предвзятость)
Как оценить качество LLM? Какие бенчмарки вы знаете (GLUE, SuperGLUE)?
Что такое model alignment? Как достигается (RLHF)?

Вопросы по Computer Vision (CV)

1. Основы обработки изображений

Что такое свёртка в контексте изображений? Как работают фильтры?
Что такое padding? Какие типы padding вы знаете?
Что такое stride в свёртке? Как он влияет на размер выхода?
Что такое pooling? Какие типы pooling вы знаете (max pooling, average pooling)?
Что такое data augmentation в CV? Приведите примеры техник.

2. Классические архитектуры CNN

Опишите архитектуру LeNet. В чём её ограничения?
Опишите архитектуру AlexNet. Какие инновации она внесла?
Опишите архитектуру VGG. В чём её особенности?
В чём преимущество ResNet перед обычными CNN? Что такое residual connections?
Опишите архитектуру Inception. В чём идея параллельных свёрток разных размеров?
Что такое depthwise separable convolutions (MobileNet)? В чём их преимущество?
Что такое EfficientNet? В чём идея compound scaling?

3. Задачи CV

Что такое image classification? Какие метрики используются?
Что такое object detection? Сравните YOLO и Faster R-CNN.
Что такое semantic segmentation? Какие архитектуры используются (U-Net, DeepLab)?
Что такое instance segmentation? Чем она отличается от semantic segmentation? (Mask R-CNN)
Опишите задачу image captioning. Какие подходы применяются?
Что такое keypoint detection? Где она применяется?

4. Modern CV Architectures

Что такое Vision Transformer (ViT)? Как он адаптирует Transformer для изображений?
Что такое Swin Transformer? В чём его отличие от классического ViT?
Что такое MLP-Mixer? Чем он отличается от ViT?
Что такое ConvNeXt? Как он сочетает CNN и Transformer идеи?

5. Практические аспекты

Как transfer learning применяется в CV? (ImageNet предобученные модели)
Что такое feature pyramid networks (FPN)? Где они используются?
Как работает Non-Maximum Suppression (NMS)?
Что такое anchor boxes в object detection?
Как оценить качество object detection? (mAP)
Что такое domain adaptation в CV?

Вопросы по Reinforcement Learning (RL)

1. Основы RL

Объясните основные компоненты задачи RL: агент, среда, состояние, действие, награда.
Что такое Markov Decision Process (MDP)?
Что такое discount factor γ? Как он влияет на обучение?
Что такое value function? Чем отличаются $V(s)$ и $Q(s,a)$?
Объясните концепцию policy. Чем отличаются deterministic и stochastic policies?

2. Value-Based Methods

Что такое Q-learning? Как оно работает?
В чём разница между on-policy и off-policy алгоритмами?
Что такое SARSA? Чем он отличается от Q-learning?
Как работает Deep Q-Network (DQN)?
Что такое experience replay и зачем он нужен в DQN?
Что такое target network в DQN? Зачем он используется?

3. Policy-Based Methods

Объясните концепцию policy gradient.
Что такое REINFORCE алгоритм? В чём его недостатки?
Что такое actor-critic архитектура?
Опишите алгоритм A2C (Advantage Actor-Critic).
Опишите алгоритм PPO (Proximal Policy Optimization). Почему он стабильнее обычного policy gradient?

Вопросы по RecSys (Recommendation Systems)

1. Основы рекомендательных систем

Что такое рекомендательные системы? Какие бизнес-задачи они решают?
Перечислите основные типы рекомендательных систем и сравните их.
Какие метрики качества используются для оценки рекомендательных систем?
В чём разница между implicit и explicit feedback? Приведите примеры.
Что такое cold start problem? Как его решать для новых пользователей и новых товаров?
Объясните концепцию long tail в рекомендательных системах.
Что такое diversity и serendipity в рекомендациях? Почему они важны?
Какие типы данных используются в рекомендательных системах (user features, item features, interaction data)?

2. Collaborative Filtering

Объясните принцип работы collaborative filtering.
В чём разница между user-based и item-based collaborative filtering?
Как рассчитывается similarity в collaborative filtering (cosine similarity, Pearson correlation)?
Что такое matrix factorization? Как она применяется в рекомендациях?
Объясните алгоритм SVD для рекомендательных систем.
Что такое implicit feedback matrix factorization (ALS)?
Какие проблемы возникают в collaborative filtering (sparsity, scalability)?
Как обрабатывать sparse matrices в рекомендательных системах?

3. Content-Based и Hybrid Systems

Объясните принцип работы content-based рекомендаций.
Как извлекать features для content-based систем (для товаров, фильмов, статей)?
Что такое TF-IDF и как он используется в content-based рекомендациях?
Как работают hybrid рекомендательные системы? Приведите примеры комбинаций.
Сравните weighted hybrid, switching hybrid и feature combination подходы.

4. Deep Learning в RecSys

Как использовать neural networks для рекомендательных систем?

Что такое Neural Collaborative Filtering (NCF)? Как он работает?
Объясните архитектуру Wide & Deep. Где она применяется?
Что такое DeepFM? Чем он отличается от Wide & Deep?
Как работают sequence-based модели в рекомендациях (GRU4Rec, SASRec)?
Что такое two-tower models для рекомендаций? Как они обучаются?
Как использовать embeddings в рекомендательных системах?
Что такое negative sampling в контексте обучения рекомендательных моделей?
Как обрабатывать многомерные категориальные признаки в DL-рекомендациях?

5. Context-Aware и Session-Based Recommendations

Что такое context-aware рекомендации? Какие контекстные факторы учитывать?
Как интегрировать временные факторы в рекомендательные системы?
Объясните подход session-based recommendations. Чем он отличается от традиционных методов?
Как работать с короткими сессиями без истории пользователя?
Что такое next-item prediction? Какие модели для него используются?

6. Scalability и Real-Time Recommendations

Как масштабировать рекомендательные системы для миллионов пользователей?
Что такое approximate nearest neighbors (ANN)? Какие библиотеки вы знаете (FAISS, Annoy)?
Как организовать real-time recommendations?
Что такое online learning в контексте рекомендательных систем?
Как обновлять рекомендации без полного переобучения модели?
Что такое candidate generation и ranking в двухэтапных системах?
Как балансировать latency и качество в production RecSys?

7. Evaluation and Metrics

Какие офлайн-метрики используются для оценки рекомендаций (Precision@k, Recall@k, MAP, NDCG)?
Что такое hit rate и how to calculate it?
Как оценить diversity и novelty рекомендаций?
В чём отличие между ranking metrics и accuracy metrics?
Как проводить A/B testing для рекомендательных систем?
Что такое offline evaluation vs online evaluation?
Какие проблемы с offline evaluation (position bias, selection bias)?
Как интерпретировать lift в контексте рекомендаций?

8. Data Pipeline и Feature Engineering

Как организовать data pipeline для рекомендательной системы?
Какие features использовать для user profiling?

Как создавать item embeddings?
Что такое behavioral features и как их извлекать?
Как работать с temporal features в рекомендациях?
Что такое feature crossing и как он применяется в RecSys?
Как обрабатывать категориальные features с высокой кардинальностью?

9. Business Constraints and Constraints Handling

Как учитывать бизнес-ограничения в рекомендациях (inventory, pricing, promotions)?
Что такое fairness в рекомендательных системах? Как её обеспечить?
Как бороться с popularity bias в рекомендациях?
Что такое exposure bias и как его корректировать?
Как обеспечить diversity в рекомендациях без потери релевантности?
Как реализовать multi-objective optimization в RecSys?

10. Advanced RecSys Architectures

Что такое YouTube DNN Recommender? Опишите его архитектуру.
Как работает Amazon's item-to-item CF в масштабе?
Опишите подход Alibaba's DIN (Deep Interest Network).
Что такое multi-task learning в контексте рекомендаций (ESMM, MMoE)?
Как использовать reinforcement learning для рекомендаций?
Что такое bandit algorithms в рекомендательных системах?
Как применять graph neural networks (GNN) для рекомендаций (PinSage)?

11. Production and MLOps for RecSys

Как деплоить рекомендательные модели в продакшн?
Что такое model serving для RecSys? Какие инструменты использовать (Triton, TF Serving)?
Как мониторить качество рекомендаций в реальном времени?
Что такое A/B testing и MAB (multi-armed bandit) testing для RecSys?
Как организовать feature store для рекомендательных систем?
Что такое backfill pipeline для feature computation?
Как управлять версиями моделей и фичей в RecSys?
Как отлаживать проблемы с рекомендациями в продакшене?
Что такое shadow mode для тестирования новых рекомендательных моделей?
Как измерять ROI от рекомендательной системы?

Основы MLOps и жизненный цикл ML-модели

Что такое MLOps? В чём его отличие от традиционного DevOps?
Опишите полный жизненный цикл ML-модели от идеи до продакшна.
Какие основные проблемы решает MLOps в ML-проектах?
Что такое ML pipeline? Какие компоненты он включает?
Какие метрики нужно отслеживать после деплоя модели в продакшн?
Что такое model drift? Какие виды дрейфа существуют (data drift, concept drift)?
Как обнаруживать и реагировать на model drift?
Что такое data lineage в контексте MLOps? Зачем он нужен?
Какие инструменты CI/CD можно использовать для ML-проектов?
Объясните концепцию «ML как код» (ML as Code).

2. Версионирование и управление экспериментами

Зачем нужно версионировать модели и данные?
Какие инструменты версионирования моделей вы знаете (MLflow, DVC)?
Как организовать версионирование данных для ML?
Что такое experiment tracking? Какие инструменты вы использовали (Weights & Biases, Comet, MLflow)?
Как структурировать эксперименты для воспроизводимости результатов?
Что хранить в experiment tracking: гиперпараметры, метрики, код, данные?
Как обеспечить воспроизводимость экспериментов (reproducibility)?

3. Контейнеризация и оркестрация (Docker, Kubernetes)

Зачем использовать Docker для ML-моделей?
Опишите процесс контейнеризации ML-модели в Docker.
Какие слои Dockerfile оптимальны для ML-приложений?
Как уменьшить размер Docker-образа для ML-модели?
Что такое multi-stage builds в Docker? Как их применять для ML?
Зачем использовать Kubernetes для ML-инференса?
Как развернуть ML-модель в Kubernetes?
Что такое Horizontal Pod Autoscaler (HPA) и как его настроить для ML-сервиса?
Как организовать rolling updates для ML-модели в Kubernetes?
Что такое Istio и как он может помочь в ML-деплое?

4. API и бэкенд для ML-сервисов

Какие подходы к созданию API для ML-моделей вы знаете (REST, gRPC)?
Сравните REST и gRPC для ML-инференса. Когда какой выбрать?
Как спроектировать REST API для ML-модели (endpoints, формат запросов/ответов)?
Что такое batch inference? Как его реализовать через API?
Как обрабатывать асинхронные запросы к ML-модели?
Как реализовать rate limiting и аутентификацию для ML API?
Какие фреймворки использовать для создания ML API (FastAPI, Flask, Django REST)?
Как организовать кэширование результатов ML-модели?
Что такое feature store? Как он интегрируется с ML API?

5. Мониторинг и Observability

Какие метрики нужно мониторить для ML-сервиса (latency, throughput, error rate)?
Как мониторить качество модели в продакшне (precision, recall, F1)?
Что такое prediction drift? Как его отслеживать?
Как настроить алертинг для ML-сервиса (пороговые значения, аномалии)?
Какие инструменты мониторинга вы использовали для ML (Prometheus, Grafana, Datadog)?
Как логировать запросы и ответы ML-модели для отладки?
Что такое model explainability в продакшене? Как её обеспечить?
Как отслеживать использование ресурсов (CPU, GPU, память) ML-сервисом?

6. Оптимизация и производительность

Как оптимизировать модель для инференса (квантование, дистилляция, pruning)?
Что такое ONNX? Как конвертировать модели в ONNX формат?
Как использовать TensorRT для ускорения инференса?
Что такое TVM и как он помогает оптимизировать ML-модели?
Как организовать batching для ML-инференса?
Как работать с GPU в продакшене (CUDA, cuDNN, multi-GPU)?
Что такое Triton Inference Server? Как его использовать?
Как организовать multi-model serving на одном сервере?

7. Data Engineering для ML

Что такое feature engineering pipeline? Как его автоматизировать?
Как организовать real-time feature computation?
Что такое streaming data для ML? Как с ним работать (Kafka, Kinesis)?
Как синхронизировать feature computation между тренировкой и инференсом?
Что такое online vs offline feature store?
Как организовать backfill данных для feature store?

8. Безопасность и Governance

Как обеспечить безопасность ML API (аутентификация, авторизация, шифрование)?
Что такое model signing? Зачем оно нужно?
Как управлять доступом к ML моделям и данным?
Что такое A/B testing для ML моделей? Как его организовать?
Как проводить canary deployment для ML моделей?
Что такое shadow deployment? Когда его использовать?

9. Инструменты и платформы MLOps

Сравните MLflow, Kubeflow и SageMaker для MLOps.
Что такое Feast? Как он помогает в feature management?
Как использовать Airflow для оркестрации ML pipelines?
Что такое Kedro? Как он структурирует ML проекты?
Как организовать CI/CD для ML с помощью GitHub Actions или GitLab CI?
Что такое TFX (TensorFlow Extended)? Какие компоненты он включает?

10. Практические кейсы и отладка

Опишите процесс деплоя ML модели от ноутбука до продакшена.
Какие ошибки чаще всего возникают при деплое ML моделей? Как их отлаживать?
Как тестировать ML API перед деплоем (unit tests, integration tests)?
Как организовать load testing для ML сервиса?
Что делать, если модель в продакшене даёт плохие результаты? План действий.
Как мигрировать с одной версии модели на другую с минимальным даунтаймом?
Как организовать rollback модели в случае проблем?
Как работать с legacy моделями в продакшене?
Что такое model registry? Как его организовать?
Как измерять ROI от внедрения MLOps практик?